

## Wspomaganie sterowania statkiem za pomocą ewolucyjnych sieci neuronowych

## Ship steering support with the use of evolutionary neural networks

Mirosław Łacki

Akademia Morska w Gdyni, Katedra Nawigacji  
81-225 Gdynia, ul. Morska 81–87 F, tel. 058 69 01 574, e-mail: lacki@am.gdynia.pl

**Słowa kluczowe:** uczenie maszynowe, algorytmy sztucznej inteligencji, ewolucyjne sieci neuronowe, sterowanie statkiem

### Abstrakt

W artykule przedstawiono koncepcję zastosowania ewolucyjnych sieci neuronowych we wspomaganie procesów podejmowania decyzji podczas manewrowania statkiem na ograniczonym obszarze. Rozważane są wybrane algorytmy, operacje genetyczne, metody kodowania i selekcji oraz struktury ewolucyjnych sieci neuronowych.

**Key words:** machine learning, artificial intelligence algorithms, evolutionary neural networks, ship steering

### Abstract

This paper describes a concept of evolutionary neural networks application in decision process support during vessel manoeuvring in a restricted area. Selected algorithms, genetic operations, methods of coding and selection, and structures of evolutionary neural networks are considered in the paper.

## Wstęp

Neuroewolucja, czyli rozwój sztucznej sieci neuronowej za pomocą algorytmów ewolucyjnych jest ostatnio bardzo intensywnie badaną dziedziną uczenia maszynowego [1]. W klasycznym projektowaniu sztucznej sieci neuronowej jednym z problemów jest dostosowanie struktury sieci, czyli liczby warstw ukrytych i liczby neuronów do rozważanego problemu tak, by wydajność sieci była optymalna.

W przypadku środowisk dynamicznych, takich jak manewrowanie statkiem na ograniczonym obszarze, optymalna topologia sieci jest trudna do wyliczenia metodami klasycznymi, dlatego też ciekawym rozwiązaniem jest zastosowanie algorytmów ewolucyjnych, których zadaniem będzie dobór parametrów sieci do postawionego problemu.

## Sztuczne sieci neuronowe


### Budowa sieci neuronowej

Struktura sztucznej sieci neuronowej podzielona jest na warstwy (wejściową, warstwy ukryte i wyjściową) (rys. 1). W każdej warstwie znajduje się określona liczba neuronów. Każdy z nich posiada jedno wyjście, którego wartość jest sumą iloczynów wartości wag i wartości sygnałów wszystkich wejść neuronu [2]. Połączenia z wartością wagi równą 0 zostały pominięte na rysunku.

Wartość sygnału wyjściowego całej sieci uzależniona jest zatem od wartości sygnałów wejściowych i wartości wag wszystkich połączeń sieci.

Klasyczne uczenie sieci polega na zastosowaniu jednej z wielu metod wyznaczania wartości poszczególnych wag połączeń. Problemem jest dobór odpowiedniej ilości warstw ukrytych oraz liczby

neuronów w tych warstwach, dlatego w artykule tym zaproponowano zastosowanie ewolucyjnych sieci neuronowych, w których nie tylko dobierane są wartości wag, lecz również topologia sieci poddawana jest operacjom genetycznym.



Rys. 1. Uproszczona struktura jednokierunkowej sztucznej sieci neuronowej

Fig. 1. Simplified structure of the one-way artificial neural network

### Ewolucyjne sieci neuronowe

W neuroewolucji sztuczna sieć neuronowa jest traktowana jako osobnik w populacji wielu sieci neuronowych. Najlepiej przystosowane osobniki stają się w wyniku selekcji i krzyżowania rodzicami nowego pokolenia, które dziedziczy cechy przodków. Nowe osobniki poddawane są procesowi mutacji, to powoduje, że w populacji mogą się pojawić osobniki o lepszym przystosowaniu. W wyniku mutacji mogą zostać zmienione nie tylko wartości wag, ale także ilość warstw lub liczba neuronów w warstwie.

Podjęcie neuroewolucyjne nasuwa kilka istotnych pytań dotyczących efektywności rozwoju sztucznych sieci neuronowych poprzez ewolucję: Jak powinien wyglądać genotyp osobnika odwzorowujący strukturę sieci neuronowej? Jak przeprowadzać krzyżowanie osobników, aby nie utracić istotnych informacji z poprzednich pokoleń? Jak uchronić nowe rozwiązania przed zbyt wczesną eliminacją z populacji?

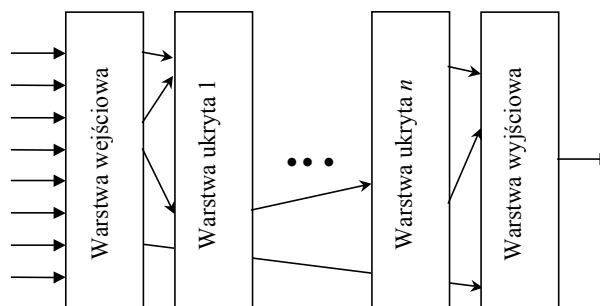
Na wszystkie te pytania można znaleźć odpowiedź, używając rozwiązania zastosowane w sieciach NEAT [3].

### Sieci NEAT

W sieciach NEAT (*NeuroEvolution of Augmenting Topologies*) za pomocą algorytmów ewolucyjnych poszukiwane są wartości wag połączeń między neuronami oraz rozwijana jest topologia sieci – od najprostszej struktury początkowej do wyspecjalizowanej złożonej struktury przystosowanej do rozwiązywanego problemu [1]. Aby skutecznie realizować operacje genetyczne, potrzebna jest odpowiednia reprezentacja genetyczna.

### Kodowanie genów


Reprezentacja genetyczna ewolucyjnej sieci neuronowej musi być dynamiczna i zdolna do rozwoju wraz ze wzrostem złożoności sieci (rys. 2).



Rys. 2. Struktura warstwową sieci neuronowej

Fig. 2. Structure of the layered neural network

W sieciach NEAT każdy genom opisujący sieć składa się z listy genów opisujących ilość neuronów w sieci oraz z listy genów opisujących połączenia między genami. W proponowanej reprezentacji genetycznej autor sugeruje dodanie do genomu informacji o ilości warstw ukrytych sieci neuronowej (rys. 3).



Rys. 3. Genom opisujący strukturę warstwową sieci

Fig. 3. Genome describing the network's layered structure

Warto zauważyć, że w proponowanym rozwiązaniu dla  $l > k$  wejście neuronu z warstwy  $l$  może być połączone z wyjściem dowolnego neuronu z warstwy  $k$ .


Lista genów opisujących połączenia między genami zawiera informację o każdym połączeniu (rys. 4) – nr warstwy i nr neuronu, z którego sygnał wychodzi, nr warstwy i nr neuronu do którego sygnał dociera, waga połączenia oraz nr innowacji.

Nr warstwy wy Nr neuronu wy	Nr warstwy wy Nr neuronu wy	...	Nr warstwy wy Nr neuronu wy
Nr warstwy we Nr neuronu we	Nr warstwy we Nr neuronu we		Nr warstwy we Nr neuronu we
Waga	Waga		Waga
Nr innowacji	Nr innowacji		Nr innowacji

Rys. 4. Genom opisujący parametry połączeń między neuronami

Fig. 4. Genome describing the connection parameters between neurons

Z tak skonstruowanego genotypu danego osobnika zawierającego informację o ilości warstw, liczbie neuronów oraz parametry połączeń między neuronami można zmapować jego strukturę (fenotyp), co pokazano na rysunku 5.



Rys. 5. Przykładowy genotyp i fenotyp sztucznej sieci neuronowej

Fig. 5. A demonstration genotype and phenotype of the artificial neural network

### Innowacja

Aby umożliwić skuteczne krzyżowanie dwóch osobników o zróżnicowanej strukturze sieci, wprowadzono do każdego genu numer innowacji. Numer ten określa, w którym momencie życia populacji dany gen pojawił się w puli genów. W przypadku powstania nowego genu jego numer innowacji jest o jeden większy od numeru innowacji ostatnio powstałego genu w populacji. Podczas krzyżowania geny o tym samym numerze innowacji zestawiane są razem i do genotypu potomka przechodzą parametry genu od lepiej przystosowanego rodzica lub odpowiednio obliczana wartość ważona genów obu rodziców [4]. Pozostałe geny (o różnych numerach innowacji) przekazywane są od obu rodziców.

### Krzyżowanie

Jak już wyjaśniono wcześniej, nowy potomek powstaje w wyniku krzyżowania informacji genetycznej dwóch osobników, którzy w drodze selekcji zostali rodzicami (rys. 6). Podczas operacji krzyżowania rodziców z puli genów o tym samym numerze innowacyjnym (ostatnia wartość w kolumnie) do genów potomka przechodzą tylko te od rodzica o lepszym przystosowaniu.

Rodzic 1

0	0	0	0	1	1	0	1
0	2	6	0	0	1	0	1
1	1	1	wy	wy	wy	wy	wy
0	2	1	0	0	0	0	0
-0,6	0,88	-0,1	0,41	-0,7	-0,2	-0,4	12
1	2	3	7	8	9	12	

Rodzic 2


0	0	1	0	1	0	0	0
0	2	1	6	1	0	0	0
1	1	2	2	2	wy	wy	wy
0	2	0	3	1	0	0	0
-0,2	0,18	0,51	0,03	-0,4	0,3	0,7	7
1	2	4	14	6	7		

Potomek

0	0	0	1	0	1	0	1
0	2	6	1	6	1	0	1
1	1	1	2	2	3	wy	wy
0	2	1	0	3	1	0	0
-0,6	0,88	-0,1	0,51	0,03	-0,4	0,41	-0,7
1	2	3	4	14	6	7	8

Rys. 6. Przykład operacji krzyżowania genetycznego – genotypy rodziców i potomka

Fig. 6. An example of the genetic crossover – genotypes of parents and a descendant



Rys. 7. Przykład operacji krzyżowania genetycznego cd. – struktura potomka

Fig. 7. An example of the genetic crossover – structure of a descendant

### Mutacja

W ewolucyjnych sieciach neuronowych procesowi mutacji genetycznej, czyli zmianie wartości parametrów nowego osobnika podlegają nie tylko wartości wag połączeń między neuronami, ale również ilość warstw sieci, liczba neuronów w warstwie i liczba połączeń między nimi.

Przed mutacją

0	0	1	0	1	0	0	0
0	2	1	6	1	0	0	0
1	1	2	2	2	wy	wy	wy
0	2	0	3	1	0	0	0
-0,2	0,18	0,51	0,03	-0,4	0,3	0,7	7
1	2	4	14	6	7		

Po mutacji

0	0	1	0	1	0	0	4
0	2	1	6	1	0	1	1
1	1	2	2	2	wy	1	1
0	2	0	3	1	0	1	1
-0,3	0,7	0,51	0,03	-0,4	0,3	0,75	15
1	2	4	14	6	7	15	

Rys. 8. Przykład mutacji wag i dodania nowego połączenia

Fig. 8. An example of the weight mutation and of addition of a new connection

Dobór prawdopodobieństw mutacji ma istotny wpływ na szybkość uczenia się sieci i jej zdolność przystosowania się do nowych warunków środowiska.

### Podział gatunkowy

W populacji sieci neuronowych o zróżnicowanych topologiach istotnym problemem jest dobór rodziców o zbliżonych genotypach. W tym celu populację dzieli się na gatunki [3]. Osobniki rywalizują i krzyżują swój materiał genetyczny jedynie w obrębie swego gatunku. Każdy nowy potomek jest przypisywany do jednego z istniejących gatunków, gdy porówna się jego genotyp do genotypu dowolnego osobnika z wybranego gatunku według wzoru:

$$\delta = \frac{c_1 E}{N} + \frac{c_2 D}{N} + c_3 \overline{W}$$

gdzie:

- $c_1, c_2, c_3$  – wagowe współczynniki istotności,
- $E$  – ilość różnych genów zewnętrznych (excess),
- $D$  – ilość różnych genów wewnętrznych (disjoint),
- $\overline{W}$  – średnia wag połączeń,
- $N$  – ilość genów większego osobnika.

Dany osobnik jest dopisany do gatunku, jeśli wartość współczynnika  $\delta$  mieści się w zakresie wartości dopuszczalnych dla danego gatunku. W przypadku gdy genotyp potomka różni się znacznie od genotypów osobników z istniejących gatunków, tworzony jest nowy gatunek, do którego przypisany zostaje ten osobnik. Podział na gatunki i współzawodnictwo w obszarze własnego gatunku pozwala uchronić nowe rozwiązania przed zdominowaniem całej populacji przez najlepiej przystosowane osobniki.

### Ewolucyjne sieci neuronowe w sterowaniu statkiem

Koncepcja użycia ewolucyjnych sieci neuronowych w sterowaniu statkiem przedstawiona jest na rysunku 9. W tej sytuacji sieć neuronowa posiada cztery wyjścia sterujące:

- dwa do tylnych śrub okrętowych,
- jedno do dziobowego steru strumieniowego,
- jedno do steru rufowego.

Na wejściach sieci neuronowej zakodowane zostały wszelkie niezbędne informacje, takie jak:

- aktualny kurs statku,
- prędkość kątowna,

- odległość do przeszkody na kursie,
- odległość i kąt do najbliższej przeszkody,
- odległość i kąt do celu,
- kąt wychylenia steru,
- prędkość statku.



Rys. 9. Propozycja zastosowania sieci neuronowych do sterowania statkiem

Fig. 9. Suggestion of neural networks use in ship control

Na początkowym etapie badań autor proponuje model uproszczony, w którym sieć steruje jedynie kątem wychylenia płetwy sterowej, przy stałej prędkości statku bez innych obiektów pływających na badanym obszarze.

### Wnioski

Z dotychczasowych badań wynika, że zastosowanie ewolucyjnych sieci neuronowych we wspomaganie sterowania statkiem jest koncepcją wartą dokładniejszej analizy. Aktualnie autor artykułu zajmuje się tworzeniem aplikacji komputerowej symulującej sterowanie statku za pomocą ewolucyjnych sieci neuronowych i być może na podstawie tych badań uda się w przyszłości skonstruować komplementarny automatyczny system manewrujący statkiem na ograniczonym obszarze.

### Bibliografia

1. KENNETH O.S., RISTO M.: Real-Time Neuroevolution in the NERO Video Game. Proceedings of the IEEE 2005 Symposium on Computational Intelligence and Games, Piscataway, 2005.
2. TOURETZKY D., MOZER M., HASSELMO M.: Neural Information Processing Systems. MIT Press, 1996.
3. KENNETH O.S., RISTO M.: Efficient Evolution of Neural Network Topologies. Proceedings of the 2002 Congress on Evolutionary Computation, Piscataway, 2002.
4. WRIGHT A. H.: Genetic algorithms for real parameter optimization. Foundations of Genetic Algorithms, San Francisco, 1991, 205–218.

Recenzent:

dr hab. inż. Zbigniew Pietrzykowski, prof. AM  
Akademia Morska w Szczecinie